

Sim-to-Real Gap: как научить робота действовать в реальном мире, если он обучался в симуляции

Вильготский Е.П.


ЦЕЛЬ РАБОТЫ

Целью настоящего исследования является экспериментальная проверка методов переноса управляющих политик, обученных с помощью глубокого обучения с подкреплением (Deep Reinforcement Learning, DRL) в виртуальной среде, на реального робота-манипулятор с минимальной потерей точности и устойчивости. В работе решается ключевая проблема современной прикладной робототехники — разрыв между симуляцией и реальностью (Sim-to-Real Gap), который возникает из-за различий в физических параметрах, сенсорном шуме и непредсказуемости реальной среды. Исследование направлено на количественную оценку этого разрыва и поиск практических методов его сокращения без дорогостоящего сбора больших объёмов реальных данных.



МЕТОДЫ


В работе использован комплексный подход, сочетающий классическую теорию управления и современные методы искусственного интеллекта. В качестве базовой линии сравнения применялся ПИД-регулятор с автоматической настройкой коэффициентов методом Ziegler–Nichols. Из методов DRL были реализованы три алгоритма: DQN для дискретных управляющих сигналов, PPO и SAC для непрерывного управления. Для преодоления Sim-to-Real Gap применялись два подхода: Domain Randomization и Domain Adaptation. Оценка эффективности проводилась на задаче достижения целевой точки с обходом статических препятствий. Критерий качества — процент успешных достижений цели за 100 попыток.



РЕЗУЛЬТАТЫ

Методология эксперимента опирается на стандарты оценки DRL в робототехнике, предложенные в работах OpenAI (2019) «Learning Dexterous In-Hand Manipulation» и Tobin et al. (2017) «Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World». Сравнительный анализ проводился относительно классических результатов Levine et al. (2018) для задачи манипуляции. Классический ПИД-регулятор показывает стабильные, но невысокие результаты. DRL-алгоритм PPO без специальных методов демонстрирует отличную точность в симуляции, однако при переносе на реального робота теряет 16 процентных пунктов, опускаясь до 78%. Это и есть количественная мера Sim-to-Real Gap. Применение Domain Randomization позволяет поднять реальную точность до 89% при незначительном снижении симуляционной точности. Наилучший результат достигнут комбинацией алгоритма SAC и Domain Adaptation: 93% в симуляции и 91% на реальном роботе. Таким образом, разрыв сокращён с 16% до 2%.

Оценка Sim-to-Real Gap для различных методов управления



ВЫВОДЫ

В результате проведённого исследования установлено, что глубокое обучение с подкреплением без дополнительной адаптации неприменимо для прямого переноса на реального робота — разрыв между симуляцией и реальностью составляет 16 процентных пунктов при решении типовой задачи манипуляции. Прямой перенос DRL-политик из симуляции на реального робота приводит к потере точности до 16%. Применение Domain Randomization сокращает разрыв до 2–3% без сбора реальных данных, что делает этот метод наиболее практичным для промышленного внедрения. Наилучший результат достигается комбинацией SAC и Domain Adaptation, но требует до 50 реальных траекторий.



Полный текст работы, обзор литературы и данные экспериментов доступны в репозитории